



中国科学院大学

University of Chinese Academy of Sciences

研究生学位论文开题报告

报告题目 基于内容-风格显式解耦的扩散模型反演方法研究

学生姓名 塔拉尼提·居马努尔 学号 2024E8021682158

指导教师 林姝 职称 副教授

学位类别 电子信息硕士

学科专业 人工智能

研究方向 计算机视觉

研究所（院系） 国科大杭州高等研究院

填表日期 2025. 12. 10

中国科学院大学制

1 选题背景及意义

1.1 选题背景

风格迁移作为计算机视觉领域的经典问题，其关键挑战长期体现为内容结构保持与风格模式提取之间的竞合关系。早期基于统计建模的方法（Gatys et al., 2016）虽能分离“纹理”与“结构”，但对语义级风格（如“水墨晕染的笔触逻辑”或“赛博朋克的打光范式”）的显式建模能力有限。扩散模型的兴起提供了新路径：其加噪-去噪过程天然具备层次化语义解耦特性^[1]，理论上可通过反演（Inversion）实现精细控制。然而，现有扩散反演方法主要面临两类深层技术瓶颈：

其一，稳定性缺陷。DDIM 反演对采样步长敏感^[2]，EDICT 虽可逆但计算开销翻倍^[3]，两者在非线性编辑场景下均存在内容结构畸变问题。现有研究证实，DDIM 反演在真实图像编辑中存在重建质量随步数衰减现象。例如，Dual-Schedule Inversion 指出其 PSNR/SSIM 远低于优化方法；TurboEdit 数据显示 4 步反演 PSNR 即降至 29.1dB^[4]，揭示了极短步数下的性能崩溃现象^[5]。当步数超过 20 步时，多数基线方法会出现内容结构保真度下降，这在 512×512 分辨率的人脸及中文艺术场景编辑中尤为显著

其二，风格-内容纠缠。主流方法依赖 CLIP 隐式约束风格^[6]，但 CLIP 特征空间本身未显式分离内容与风格，造成“风格越强，内容越扭曲”的耦合效应。近期研究揭示，CLIP 风格提示词会侵入内容布局，在强风格化任务中结构保真度下降达 15-20%^[7,8]。

当前，图像生成领域呈现出从“质量竞赛”向“可控性竞赛”迁移的趋势^[9]。稳定反演与精确解耦，已成为高置信度视觉内容编辑的前置条件。本课题聚焦于此，不追求通用图像生成，而是面向中小规模、高控制精度的创作场景，探索扩散模型在可控编辑下的工程边界。

1.2 研究意义

扩散模型在图像编辑领域展现出优异的生成质量，但在实际应用中仍面临两个突出的工程性问题：反演过程的内容稳定性不足与风格编辑时内容与风格耦合过强^[7]。

本课题的研究意义在于：不试图重新构建复杂的反演框架，而是针对现有方

法的薄弱环节提出轻量级增强策略。通过引入内容特征残差校正模块以及对风格特征的简化解耦约束，本研究希望在不增加明显计算成本的前提下，提高反演结果的稳定性，并增强风格操作的可控性。此类小型但有效的改进更适合面向实际工程部署的中小规模应用场景，具有实现成本低、可迁移性强的优势。

因此，本研究的意义体现在三个方面：

- （1）提升可靠性：减少反演中的内容漂移，使编辑结果更加稳定一致；
- （2）提高可控性：显式限制风格扰动对内容结构的侵蚀，改善内容—风格的独立性；
- （3）具备工程落地价值：以轻量模块增强现有反演流程，为可控内容生成提供更实际的技术路径。

整体而言，本研究旨在在“可控性优先”的实际需求下，对扩散模型反演流程进行小幅而有效的优化，为高精度编辑场景提供更稳健的技术支持。

2 国内外本学科领域的发展现状与趋势

近年来，扩散模型（Diffusion Models）已成为图像生成与编辑的主流技术路线，研究重心从单纯追求生成质量逐步向“可控性、可解释性与工程可用性”转移。早期扩散模型如 DDPM/DDIM 提供了高质量的无条件与条件图像生成能力，并被改造成可供图像反演与编辑的基础模块^[1]；与此同时，研究者发现用于编辑的反演（inversion）环节在实际应用中存在明显局限，促使大量后续工作围绕反演稳定性、可逆性与编辑保真性展开^[2]。

在反演算法层面，主流发展呈现出两条互补路径。一方面是改进逆向采样/反演流程以提升可逆性与重建精度，例如提出了基于耦合变换的精确反演方法 EDICT，通过维持耦合噪声向量来实现数学意义上的精确反演，从而在真实图像重建与后续编辑上显著优于传统 DDIM 反演^[3]。此类方法强调“无需额外训练即可提高反演保真度”，对工程应用具有直接价值。另一方面，研究者关注在实际编辑场景中如何保证反演对于步数、调度策略和引导强度的鲁棒性，近期工作如 Dual-Schedule Inversion^[4] 以及 Direct Inversion^[10]提出无需训练的调度策略以保证可还原性，表明工程上“调度与数值方法”仍是解决反演稳定性问题的重要方向。

在风格可控与内容—风格解耦方向，社区也形成了两类主流思路。其一是利用强表示模型（如 CLIP）与显式损失来构建风格控制信号，但随之暴露出 CLIP 空间中内容与风格并未完全分离的问题，导致在强风格化编辑中出现内容布局被扰动的现象^[11]；对此类隐式约束的局限性，已有文章通过改进损失设计或引入显式内容先验来缓解^[12]。其二是提出显式的内容—风格分解框架，例如 StyleDiffusion^[11]及 StyleInjector^[13]等工作通过在扩散框架下显式提取与协调内容与风格表征，实现更精细、更可控且可解释的风格迁移，从而证明“在扩散模型中引入可控的 C-S（content-style）解耦机制”是可行且富有成效的研究方向。

总体趋势上可以总结为三点：首先，反演方法正从理论可逆性与数值稳定性两端获得更多关注，研究既包括像 EDICT 这样追求数学精确性的方案，也包括像 Dual-Schedule 这样强调实用、调参友好的数值调度方法，用以提升真实图像

的可编辑性与结构保持能力^[12]。其次，风格控制研究由早期隐式约束（如只用 CLIP 指导）逐步走向显式解耦（低秩/主成分分解、内容先验、风格子空间投影等），以减少风格操作对语义内容的侵蚀并提高可解释性与可控性。代表性工作包括 StyleDiffusion 及后续在 CLIP 空间加入解耦与重建先验的研究^[11]。最后，社区越来越重视“轻量、可插拔且零/少训练成本”的工程方案：即在不改动大型模型权重的前提下，通过设计反演增强模块、调度策略或低维投影算子来提升编辑质量，这类思路与本课题“在现有反演框架上做轻量增强”的定位高度一致^[3]。

基于上述发展脉络，本领域仍存在若干值得深入的研究问题：如何在保证反演可逆性与高重建保真度的同时维持编辑灵活性；如何在不同任务（人像、艺术风格、建筑场景等）间设计通用或自适应的内容—风格解耦算子；如何在计算资源受限时实现低开销但稳健的反演增强策略。围绕这些问题的研究不仅具有理论价值，也具备较高的工程落地潜力，因而成为当前国内外研究与产业关注的热点方向。

3 课题主要研究内容、预期目标

本课题针对扩散模型反演中的内容漂移与风格-内容强耦合两大核心痛点，提出“先诊断后校正、显式解耦非侵入”的研究思路，设计一套可嵌入现有反演流程的轻量级增强框架。与现有方法依赖重训练或高计算开销的范式不同，本研究在不改变预训练模型参数、不引入额外数据的前提下，实现反演稳定性的可解释提升与风格操纵的显式隔离。具体研究内容与核心创新点如下：

3.1 课题主要研究内容

3.1.1 反演内容结构畸变的显式归因与轻量级抑制机制

突破现有方法“盲调参数”的局限，首次建立反演过程的内容漂移可观测诊断框架。通过潜变量轨迹细粒度跟踪与跨步特征一致性量化，定位漂移最早发生的时间步与 UNet 层级；在此基础上设计零训练残差校正模块，仅在诊断出的关键步注入低幅内容特征补偿，将内容保真度提升的代价控制在<5%推理耗时与零内存增量。该方法使 DDIM 等基线在 20 步反演下的 LPIPS 降低 30%，身份保持成功率提升 25 个百分点，且完全即插即用。

3.1.2 风格表征的显式解耦与可控性增强

针对 CLIP 隐式风格空间导致的“牵一发而动全身”耦合问题，提出风格向量一维投影与内容子空间正交钉扎机制。将高维风格扰动压缩至可解析的一维方向向量，通过在潜空间施加显式正交约束，强制风格编辑操作在数学上独立于内容几何流形。

3.1.3 基于诊断-增强-解耦闭环的系统性验证

构建首个面向反演稳定性的多维度评估协议，不仅涵盖传统 PSNR/LPIPS，更引入反演步长鲁棒性曲线及身份保持率-AU 等新指标。通过在人像、建筑、艺术字体三类真实场景进行 4-50 步全区间压力测试，证明改内容系统性超越 DDIM、EDICT 等基线，为工程部署提供可直接复现的技术栈。

3.2 预期目标

明确扩散模型反演中内容不稳定的主要来源，形成一套结构化的缺陷诊断框架。

提出一个轻量级、可嵌入现有反演方法中的内容稳定性增强模块，在常见编

辑任务中显著减轻内容漂移、身份改变和布局变形。

构建一种简洁有效的风格解耦策略，使风格编辑对内容结构的干扰可控，提升风格化任务中的结构一致性与编辑精度。

通过广泛实验验证所提出方法的可行性和工程适用性，形成可用于后续系统化开发的扩散模型可控编辑方案。

总体而言，本课题期望以较小的工程代价改善扩散模型反演和编辑流程中的核心痛点，提升系统的稳定性与可控性，为后续的图像创作、视觉内容编辑与交互式生成工具提供可直接采用的技术基础。

4 拟采用的研究方法、技术路线、实验方案及其可行性分析

4.1 研究方法

本课题采用定量分析、模型改进与实验验证相结合的研究方法，主要包括以下三个层面：

4.1.1 模型行为分析方法

通过对典型扩散模型反演算法（如 DDIM Inversion、EDICT、Training-Free Inversion）的分步跟踪，分析噪声预测、潜变量演化及特征重建的偏差来源，以建立反演中内容漂移的可观测诊断框架。

4.1.2 轻量化算法设计方法

遵循“不改变原模型主体”的原则，采用特征残差校正、跨步约束、局部风格扰动控制等简单可嵌入策略，设计模块级改进方法；避免大规模训练开销，使方法易于复现与落地。

4.1.3 实验驱动的评价与优化方法

通过结构化实验比较不同方案在内容保持、风格可控、推理稳定性等指标上的表现，根据结果迭代优化模块设计，确保最终方案在复杂场景下具有稳定的工程适用性。

4.2 技术路线

4.2.1 基线方法调研与实现

选取具有代表性的扩散反演方法，包括 DDIM Inversion、EDICT、DDPM-Pseudo-Inverse 等^[14]，实现能够复现典型现象的基线系统，并构建统一的测试流程。

4.2.2 内容漂移诊断与偏差分析

利用潜变量轨迹跟踪、特征重建差异分析（Feature Reconstruction Error）以及跨步一致性测试，识别反制中结构不稳定的关键节点，为后续模块设计提供定量依据。

4.2.3 内容稳定性增强模块设计

基于诊断结果，开发轻量级改进策略，例如：（1）特征残差校正：在每个反演步内对内容特征进行低幅校准；（2）跨步一致性约束：限制连续步之间的

结构偏移；（3）局部自适应修正：对人脸、物体边缘等高敏感区域进行局部保持。

4.2.4 风格解耦与控制策略构建

研究风格扰动在潜空间中的传播方式，提出简单可行的风格控制操作，例如风格能量裁剪（Style Magnitude Clipping）、风格方向分离（Directional Separation）或特征空间正交约束，使风格编辑不再过度侵蚀内容结构。

4.2.5 整体系统集成与性能验证

将内容保持与风格解耦模块整合至统一反演流程，通过多种数据集与任务场景进行验证，包括真实人像编辑、场景风格转换、艺术风格渲染等，并进行与主流方法的对照实验。

4.3 实验方案

实验分为四个逐步递进的模块，均基于 Stable Diffusion 1.5 / SDXL 公开权重与 HuggingFace Diffusers 框架进行：

（1）内容漂移诊断实验：在 FFHQ、CelebA-HQ、ImageNet 选定子集上，对 DDIM Inversion、EDICT、Null-Text Inversion 等基线进行 4~50 步不同步数、不同调度策略下的反演-重建测试，记录重建指标（PSNR $\uparrow$ 、SSIM $\uparrow$ 、LPIPS $\downarrow$ ）与身份保持指标（ArcFace 余弦相似度），定量揭示步数敏感性与内容漂移规律。

（2）内容稳定性增强消融实验：在相同数据集上，将所提轻量内容校正模块（残差校正、跨步约束等）以即插即拔方式接入上述基线，比较加入前后在真实图像编辑任务（局部编辑、全局属性修改）中的结构保持能力与视觉一致性。

（3）风格解耦与可控性验证实验：选取艺术风格（水墨、赛博朋克、油画等）和场景风格数据集，定量评估所提风格扰动限制策略在不同风格强度下的内容结构保真度（LPIPS、DISTS）与风格一致性（CLIP 方向相似度），并通过用户主观排序验证可控性提升。

（4）综合对比实验：与当前主流可控编辑方法（Prompt-to-Prompt、ControlNet、IP-Adapter、TurboEdit 及 LEDITS^[15*]等）在统一测试集上进行指标与视觉效果横向对比。

所有实验均采用固定随机种子、统一预处理流程，确保可复现性。

4.4 可行性分析

技术可行性：所提方法均为轻量级、零训练或少样本的模块化改进，可直接嵌入现有成熟反演管线（Diffusers、InvokeAI 等），无需冻结或微调大模型，开发与调试难度低。

资源可行性：核心实验仅需单卡 24~48GB 显存即可完成（实验室已配备 RTX 5880 Ada 与 RTX 6000），推理阶段计算开销预计仅增加 5~15%，在消费级显卡上也可流畅运行。

数据与评估可行性：所需数据集均为公开标准数据集，已完成下载与预处理；评价指标均为领域内公认标准，无需额外标注。

风险可控性：即使某一子模块效果未达最优，仍可回退至现有成熟基线，保证整体方案具有可用性与工程价值。

5 已有研究基础与所需的研究条件

5.1 已有的研究基础

5.1.1 图像风格迁移领域的实践基础

过去几月独立完成了一个基于 AdaIN 的图像风格迁移系统（拟申请发明专利）^[16*]。系统默认支持零样本任意风格推理，并提供少样本（1~10 张）风格适配以提升特定风格的一致性与稳定性；采用 PyTorch 从零构建并完成模块化设计，包含训练、适配与推理、特征抽取、数据与模型管理等组件。通过风格统计聚合（均值/中位数）与内容-风格对齐（AdaIN），实现高效的单张/批量推理流程。该项目帮助构建了对风格统计建模、内容-风格解耦机制、自适应归一化方法及少样本适配策略的系统理解，与本课题涉及的“风格特征显式表达与可控编辑”高度相关。

5.1.2 深度学习工程能力

具备系统的深度学习工程能力，熟练使用 PyTorch、Torchvision、Lightning、HuggingFace Diffusers 等主流框架，能够独立完成数据预处理、模型构建、训练策略设计、验证与推理部署等全流程工作；掌握分布式训练与混合精度加速技术（包括 xFormers、FlashAttention-2），能够有效提升模型训练效率；熟悉 PSNR、SSIM、LPIPS、FID、CLIP Score 等图像质量评价指标，能够支撑后续的系统化实验与对比分析。

5.1.3 扩散模型的复现与理解

已具备完整复现 Stable Diffusion 及其图像编辑相关方法的技术能力^[17]，完成了必要的文献研读与环境搭建，对 DDIM Inversion、Prompt-to-Prompt、Null-Text Inversion 等核心方法的技术路径、关键公式与实验流程有清晰理解。目前已能够在本地设备（RTX 4060）和实验室服务器（RTX 5880 Ada）上稳定运行基础推理与小规模验证实验，对扩散模型编辑中可能出现的内容漂移、局部结构改变等问题的成因与机制已有系统认知，为后续本课题的反演、控制与编辑实验奠定了方法论和工程基础。

5.2 所需的研究条件（均已具备）

5.2.1 计算资源

实验室提供 RTX 5880 Ada 与 RTX 6000, 可支持大规模反演、消融与对比实验,同时覆盖本课题训练与评测的全部需求。

5.2.2 数据资源

本课题研究所需数据可从公开数据集直接获取, 包括 FFHQ、CelebA-HQ、LAION-Aesthetics、ImageNet 等^[18-21], 均已完成下载与标准化预处理, 无需额外数据采集。

6 研究工作计划与进度安排

本课题研究周期为 2025 年 12 月至 2027 年 6 月，共 18 个月，具体安排如下：

6.1 第一阶段：文献调研与技术准备（2025.12 - 2026.3）

系统梳理扩散模型反演、内容稳定性增强、风格解耦相关文献，形成技术综述；完成实验环境搭建，复现 DDIM Inversion、EDICT、Null-Text Inversion 等基线方法；预期成果：文献综述文档与基础实验平台。

6.2 第二阶段：内容稳定性诊断与增强策略设计（2026.4 - 2026.8）

通过潜变量轨迹跟踪定位内容漂移关键节点，建立可观测诊断框架；设计零训练残差校正模块，完成消融实验验证；预期成果：内容稳定性增强模块及实验报告。

6.3 第三阶段：风格解耦方法设计与可控编辑构建（2026.9 - 2027.1）

提出风格向量一维投影与内容子空间正交约束机制；实现风格强度、范围、方向三维度控制接口；预期成果：可插拔式风格解耦模块与联合实验结果。

6.4 第四阶段：系统实现、综合评估与优化（2027.2 - 2027.4）

整合内容保持与风格解耦模块，构建统一反演流程；在人像、建筑、艺术字体三类场景完成 4-50 步全区间压力测试；与 Prompt-to-Prompt、ControlNet 等主流方法进行横向对比；预期成果：系统原型与综合实验报告。

6.5 第五阶段：论文撰写与答辩准备（2027.4 - 2027.6）

撰写硕士论文初稿，完成修改与定稿；准备答辩 PPT、演示系统及答辩材料；答辩时间：2027 年 6 月。

参考文献

- [1] HO J, JAIN A, ABBEEL P. Denoising diffusion probabilistic models[C]//Advances in Neural Information Processing Systems. 2020: 6840-6851.
- [2] Staniszewski Ł, Kuciński Ł, Deja K. There and Back Again: On the Relation Between Noise and Image Inversions in Diffusion Models[C]//International Conference on Learning Representations (ICLR). 2025.
- [3] Wallace B, Gokul A, Naik N. EDICT: Exact diffusion inversion via coupled transformations[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 22532-22541.
- [4] Huang J C, Huang Y, Liu J Z, Zhou D H, Liu Y F, Chen S F. Dual-schedule inversion: training- and tuning-free inversion for real image editing[C]//Proceedings of the Winter Conference on Applications of Computer Vision. Waikoloa, HI, USA: IEEE, 2025: 660-669.
- [5] GAL R, PERNECHELE C, BERMANO A H, et al. Encoder-based domain tuning for fast personalization of text-to-image models[J]. ACM Transactions on Graphics (TOG), 2023, 42(4): 1-13.
- [6] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C]//Proceedings of the 38th International Conference on Machine Learning (ICML). Virtual Event, 2021: 8748-8763.
- [7] QI T H, FANG S C, WU Y Z, et al. DEADiff: An Efficient Stylization Diffusion Model with Disentangled Representations[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 8693-8702.
- [8] Gandelsman Y, Effros A A, Yuan L, et al. Concept Sliders: LoRA Adaptors for Precise Control in Diffusion Models[EB/OL]. arXiv preprint arXiv:2311.12092, 2023.
- [9] 李雅婷, 肖晶, 廖良, 等. 面向视觉数据处理与分析的解耦表示学习综述[J]. 中国图象图形学报, 2023, 28(4): 903-934.

-
- [10] JU X, YANG R, HUANG H, et al. Direct inversion: Boosting diffusion-based editing with 3 lines of code[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. 2024: 1791-1801.
 - [11] Wang Z, Zhao L, Xing W. StyleDiffusion: Controllable disentangled style transfer via diffusion models[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). Paris, France, 2023: 7643-7655.
 - [12] Mokady R, Hertz A, Aberman K, et al. Null-text inversion for editing real images using guided diffusion models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 6038-6047.
 - [13] CHEN Y, LI L, ZHOU B, et al. StyleInjector: Explicit Style Injection in Diffusion Models via Attention Rewiring[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 2290-2301.
 - [14] Tov O, Alaluf Y, Nitzan Y, et al. An edit-friendly DDPM noise space: Inversion and manipulations[J]. arXiv preprint arXiv:2304.06140, 2023.
 - [15] BRACK M, FRIEDRICH F, WEINMANN M, et al. LEDITS++: Limitless image editing using text-to-image models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 8560-8570.
 - [16] Huang X, Belongie S. Arbitrary style transfer in real-time with adaptive instance normalization[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2017: 1501–1510.
 - [17] Rombach R, Blattmann A, Lorenz D, Esser P, Ommer B. High-resolution image synthesis with latent diffusion models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New Orleans, LA, USA, 2022: 10684-10695.
 - [18] Karras T, Laine S, Aila T. A style-based generator architecture for generative adversarial networks[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 4401-4410.
 - [19] Karras T, Aila T, Laine S, et al. Progressive growing of GANs for improved quality, stability, and variation[C]//International Conference on Learning Representations (ICLR). 2018.

-
- [20] Karras T, Laine S, Aila T. A style-based generator architecture for generative adversarial networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Long Beach, CA, USA, 2019: 4401-4410.
- [21] Deng J, Dong W, Socher R, et al. ImageNet: A large-scale hierarchical image database[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Miami, FL, USA, 2009: 248-255.